

### 3. 파이썬과 벡터화

#### 벡터화(Vectorization)

- 코드에서 for문 없앨 수 있음
- 결과를 빠르게 얻기 위해 큰 데이터를 학습시킬 때 코드가 빠르게 실행되는 게 중요 (아이디어 → 피드백 속도 빠름)

What is vectorization?

$$z = \underline{w^T x} + b$$

Non-vectorized:

```
z = 0
for i in range(n-x):
    z += w[i] * x[i]
z += b
```

$$w = \begin{bmatrix} : \\ : \\ : \end{bmatrix} \quad x = \begin{bmatrix} : \\ : \\ : \end{bmatrix}$$

$$w \in \mathbb{R}^{n_x}$$

$$x \in \mathbb{R}^{n_x}$$

Vectorized

$$z = \underbrace{\text{np.dot}(w, x)}_{w^T x} + b$$

→ GPU } SIMD - single instruction  
→ CPU } multiple data.

Andrew Ng

- 벡터화되지 않으면?
  - for문을 돌며  $z += w[i] * x[i]$  연산을 해주어야 함.
- 벡터화되면?
  - $w^T x$  직접 계산!
  - $\text{np.dot}(w, x) = w^T x$
  - 더 빠름

예시: Jupiter Notebook 코드

- Shift + Enter 코드 실행

```
import time
a = np.random.rand(1000000) # 랜덤 수로 이루어진 백만 차원의 배열
b = np.random.rand(1000000)

tic = time.time() # 계산 전 시간
c = np.dot(a, b) # 벡터화
toc = time.time() # 계산 완료 시간

print("Vectorized: " + str(1000*(toc-tic)) + "ms")

c = 0
tic = time.time()
for i in range(1000000):
    c += a[i] * b[i]
toc = time.time()

print("For loop: " + str(1000*(toc-tic)) + "ms")
```

```
Vectorized: 1.47...ms
For loop: 474.29...ms
```

→ 벡터화하면 코드 실행 속도가 300배 가량 상승됨!

## 그렇다면 속도에서 차이가 나는 이유는?

→ GPU } SIMD - single instruction  
→ CPU } multiple data.

- GPU와 CPU에게는 **병렬 명령어: SIMD**(Single Instruction Multiple Data)가 있음
  - GPU가 CPU 보다 SIMD 계산에 뛰어남
- np.dot 또는 for문 대신 다른 함수를 사용할 때, **파이썬의 NumPy가 병렬화를 통해 계산을 훨씬 빠르게 수행하게 해줌**
- 가능한, **for문은 쓰지 말자!**

## 더 많은 벡터화 예제

### 1. 행렬 A와 벡터 v의 곱인 벡터 u 계산

벡터화 X vs 벡터화 O

$$u = Av$$
$$u_i = \sum_j A_{ij} v_j$$
$$u = \text{np.zeros}(n, 1)$$
$$\text{for } i \dots \leftarrow$$
$$\text{for } j \dots \leftarrow$$
$$u[i] += A[i][j] * v[j]$$
$$u = \text{np.dot}(A, v)$$

→ for문 2개를 없애므로 훨씬 빠르다!

### 2. 벡터 v의 모든 원소에 지수 연산

= 원소가  $e^{(v_1)}$  부터  $e^{(v_n)}$ 인 벡터 u 계산

$$v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} \rightarrow u = \begin{bmatrix} e^{v_1} \\ e^{v_2} \\ \vdots \\ e^{v_n} \end{bmatrix}$$

```
→ u = np.zeros((n, 1))  
→ for i in range(n):  
    → u[i] = math.exp(v[i])
```

```
import numpy as np  
u = np.exp(v)
```

- $\text{np.exp}(v) \rightarrow e^v$
- $\text{np.exp}(a, b) \rightarrow a^b$
- $\text{np.log}(v) \rightarrow$  각 원소의 로그값 계산

- `np.abs(v)` → 절댓값
- `np.max(v, 0)` → 원소와 0 중에서 더 큰 값 반환
- `v**2` → 모든 원소 제곱
- `1/v` → 모든 원소 역수

→ for문을 쓰고 싶을 때, 해당하는 NumPy 내장 함수가 있는지 확인!

## Logistic Regression에 적용

- 두 개의 for문이 있었음.
1. 훈련 세트를 도는 for문
  2. 입력 벡터의 차원 n만큼 도는 반복문 → 이걸 없앨 것!

### Logistic regression derivatives

$J = 0, \text{ ~~dw1 = 0, dw2 = 0~~, } db = 0$        $dw = np.zeros((n_x, 1))$   
 → for i = 1 to n:  
      $z^{(i)} = w^T x^{(i)} + b$   
      $a^{(i)} = \sigma(z^{(i)})$   
      $J += -[y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})]$   
      $dz^{(i)} = a^{(i)}(1 - a^{(i)})$   
     ↓  $\text{for } j=1 \dots n_x$   
      $\left[ \begin{array}{l} \text{~~dw1 += x_1^{(i)} dz^{(i)}~~ } \\ \text{~~dw2 += x_2^{(i)} dz^{(i)}~~ } \end{array} \right] \quad n_x=2$        $dw += x^{(i)} dz^{(i)}$   
      $db += dz^{(i)}$   
 $J = J/m, \text{ ~~dw1 = dw1/m, dw2 = dw2/m~~, } db = db/m$        $dw /= m.$

Andrew Ng

### 코드에서 달라진 점

1. 초기화: dw들을 0으로 초기화하는 대신, n차원의 벡터로 만든다.

```
dw = np.zeros((n_x, 1)) # n_x차원의 벡터
```

2. 반복되는 부분을 벡터 연산으로 대체한다.

```
dw += x^(i)*dz(i)
```

3. 평균을 구하는 부분도 간략하게 표현한다.

```
dw /= m
```

for문을 하나만 없애도 속도가 매우 올라가지만, for문을 하나도 쓰지 않고 훈련 세트를 동시에 처리할 수 있는 법이 있음!

## 로지스틱 회귀의 벡터화

### 1. 정방향 전파 단계

$$\begin{aligned} \underline{z^{(1)}} &= w^T x^{(1)} + b & \underline{z^{(2)}} &= w^T x^{(2)} + b & \underline{z^{(3)}} &= w^T x^{(3)} + b \\ \underline{a^{(1)}} &= \sigma(z^{(1)}) & \underline{a^{(2)}} &= \sigma(z^{(2)}) & \underline{a^{(3)}} &= \sigma(z^{(3)}) \end{aligned}$$

m개의 훈련 샘플이 있다면, m번 동안 z와 활성값을 계산해야 함.

- X는 훈련 입력을 열로 쌓은 행렬 (n, m)차원

$$X = \begin{bmatrix} x^{(1)} & x^{(2)} & \dots & x^{(m)} \\ 1 & 1 & \dots & 1 \end{bmatrix}$$

### z 계산하기

- (1, m) 크기의 행 벡터

$$\underline{z} = [\underline{z^{(1)}} \quad \underline{z^{(2)}} \quad \dots \quad \underline{z^{(m)}}] = \underline{w^T X} + \underline{[b \quad b \quad \dots \quad b]} = \begin{bmatrix} w^T x^{(1)} + b \\ w^T x^{(2)} + b \\ \dots \\ w^T x^{(m)} + b \end{bmatrix}$$

$\underline{Z}(\underline{z}$ 를 쌓은 행 벡터) = `np.dot(w.T, X) + b` # `np.transpose(W)`

- 브로드캐스팅: b는 실수지만, 이 벡터와 더하면 자동으로 (1, m) 벡터로 변환

### a 계산하기

- 시그모이드 함수 구현 필요
- Z 전체를 입력으로 받아 A 전체 출력

## 로지스틱 회귀의 경사 계산 벡터화

### db 계산하기

$$db = \frac{1}{m} \sum_{i=1}^m dz^{(i)}$$

$$= \frac{1}{m} \text{np.sum}(dz)$$

최종 db = i가 1부터 m까지일 때, dz(i)의 합을 m으로 나눈 값

- $db = 1/m * \text{np.sum}(dZ)$

### dw 계산하기

$$dw = \frac{1}{m} X dz^T$$

$$= \frac{1}{m} \begin{bmatrix} x^{(1)} & \dots & x^{(m)} \\ 1 & & 1 \end{bmatrix} \begin{bmatrix} dz^{(1)} \\ \vdots \\ dz^{(m)} \end{bmatrix}$$

$$= \frac{1}{m} \left[ \underbrace{x^{(1)} dz^{(1)}}_{n \times 1} + \dots + \underbrace{x^{(m)} dz^{(m)}}_{n \times 1} \right]$$

최종  $dw = 1/m * X * dZ^T$

## 최종 코드

```
z = w.T * X + b
    = np.dot(w.T, X) + b
A = σ(z)
dz = A - Y
dw = 1/m * X * dz.T
db = 1/m * np.sum(dz)

w := w - α dw
b := b - α db
```

1. Z, A를 벡터화해 한 번에 연산
2.  $dz = A - Y$
3.  $db = 1/m * np.sum(dz)$ ,  $dw = (1/m) * X * dz^T$

→ 경사하강법의 한 반복을 구현한 것, 경사하강법을 여러 번 적용하려면 for문 필요

## 브로드캐스팅(Broadcasting)

- 파이썬 코드 실행 시간을 줄일 수 있는 기법

### 예시 1: 사과, 고기, 계란, 감자의 탄수화물, 단백질, 지방 칼로리 함유량

Calories from Carbs, Proteins, Fats in 100g of different foods:

	Apples	Beef	Eggs	Potatoes
Carb	56.0	0.0	4.4	68.0
Protein	1.2	104.0	52.0	8.0
Fat	1.8	135.0	99.0	0.9

- 목표: 네 가지 음식의 탄수화물, 단백질, 지방이 주는 칼로리의 백분율을 구하는 것
  - for문 없이 수행할 수 있는가? → 가능!

```
cal = A.sum(axis=0) # 세로로 더함
percentage = 100 * A / cal.reshape(1, 4) # 브로드캐스팅
```

- A.sum(axis=0)
  - 세로로 더함(가로는 axis = 0)
- cal.reshape(1, 4)
  - (3, 4) 행렬인 A를 (1, 4) 행렬로 나눈다.
  - 행렬의 크기가 확실하지 않다면 reshape 함수로 확실히 해준다.
  - 상수 시간이 소요되어 호출이 가볍다.

## 예시 2: 상수 더하기

$$\begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} + \begin{bmatrix} 100 \\ 100 \\ 100 \\ 100 \end{bmatrix} = \begin{bmatrix} 101 \\ 102 \\ 103 \\ 104 \end{bmatrix}$$

(4, 1) 벡터에 상수 100을 더한다면, 파이썬에서는 자동으로 100을 브로드캐스팅해 모든 요소가 100인 (4, 1) 벡터로 만들어준다.

## 예시 3: 열이 같은 행렬 연산

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} + \begin{bmatrix} 100 & 200 & 300 \\ 100 & 200 & 300 \end{bmatrix} = \begin{bmatrix} 101 & 202 & 303 \\ 104 & 205 & 306 \end{bmatrix}$$

$(m, n) \quad (2,3)$        $(1, n) \rightsquigarrow (m, n) \quad (2,3)$

(m, n) 행렬에 (1, n) 행렬을 더한다면, 파이썬은 두 번째 행렬을 m번 세로로 복사해서 (m, n) 행렬로 만들어준다.

## 예시 4: 행이 같은 행렬 연산



$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}_{(m,n)} + \begin{bmatrix} 100 & 100 & 100 \\ 200 & 200 & 200 \end{bmatrix}_{(m,1)} = \begin{bmatrix} 101 & 102 & 103 \\ 204 & 205 & 206 \end{bmatrix}_{(m,n)}$$

(m, n) 행렬과 (m, 1) 행렬을 더한다면, 파이썬은 두 번째 행렬을 n번 가로로 복사해서 (m, n) 행렬로 만들어준다.

## Generalization

$$\begin{array}{ccc} (m, n) & + & (1, n) \rightsquigarrow (m, n) \\ \text{matrix} & \times & \\ \hline & / & (m, 1) \rightsquigarrow (m, n) \end{array}$$

(m, n) 행렬과 (1, n) 행렬/(m, 1) 행렬을 사칙연산하면 더 큰 행렬의 크기에 맞게 복사하여 요소별 연산

$$\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}_{(m,1)} + \begin{matrix} 100 \\ 100 \\ 100 \end{matrix}_{(1,n)} = \begin{bmatrix} 101 \\ 102 \\ 103 \end{bmatrix}_{(m,n)}$$

(m, 1) 행렬 혹은 열 벡터에 실수와 사칙연산을 하면 실수를 행렬에 크기에 맞게 복사하여 요소별 연산

## 파이썬과 넘파이 벡터

- 브로드캐스팅은 장점이자 약점
  - 장점: 넓은 표현성과 유연성
  - 약점: 내용 이해를 못 하면 찾기 어려운 오류가 생김 (ex) 행 벡터 + 열 벡터)

## 교수님의 코드 조언



크기가 (n,) 또는 랭크가 1인 배열을 사용하지 않는다. 대신, 행 벡터나 열 벡터를 사용한다.

```
a = np.random.randn(5)    # 크기: (5,)
a = np.random.randn(5, 1) # 크기: (5, 1)
```

- `np.random.randn(5)`
  - 가우시안 분포를 따르는 변숫값 5개를 배열 `a`에 저장
  - 전치, `a`와 `a`의 전치의 내적 연산이 정상적으로 실행되지 않음.
- `np.random.randn(5, 1)`
  - `a`는 5×1 열 벡터
  - 전치

```
print(a.T)
```

```
[ 0.50290632 -0.29691149  0.95429604 -0.82126861 -1.46269164]
```

```
print(np.dot(a,a.T))
```

```
4.06570109321
```

```
a = np.random.randn(5,1)
print(a)
```

```
[[-0.0967311 ]
 [-2.38617377]
 [-0.3243588 ]
 [-0.96216349]
 [ 0.54410384]]
```

```
print(a.T)
```

```
[[ -0.0967311  -2.38617377 -0.3243588  -0.96216349  0.54410384]]
```

- `a`와 `a`의 전치의 내적: 벡터의 외적, 즉 행렬

## 랭크 1 벡터를 사용하지 않는 세 가지 방법

```
a = np.random.randn(5, 1)

assert(a.shape == (5, 1))

a = a.reshape((5, 1))
```

- `assert(a.shape == (5, 1))`
  - `a`가 (5, 1) 열 벡터라는 걸 확실히 하는 함수
  - 필요할 때 언제나 써도 좋음
- `a = a.reshape((5, 1))`
  - `a`가 랭크 1 벡터였어도 `reshape` 함수를 통해 행 또는 열 벡터로 바꿀 수 있음

## Jupyter/iPython Notebooks 가이드

1. Start code here, End code here 사이에 코드 적기
2. 코드 실행: Shift + Enter
3. 커널이 작동하지 않는다는 오류: Kernel 탭 → Restart
4. 라이브러리 코드들도 실행
5. Submit assignment 눌러서 채점

## 로지스틱 회귀의 비용함수 설명

- 로지스틱 회귀에 왜 그 비용 함수를 쓰는지

$$\begin{aligned} \text{If } y = 1: & \quad p(y|x) = \hat{y} \\ \text{If } y = 0: & \quad p(y|x) = 1 - \hat{y} \end{aligned}$$

- $y$ 는 1이거나 0임. 이 두 식을 합치면 아래의 식이 됨.

$$p(y|x) = \hat{y}^y (1-\hat{y})^{(1-y)}$$

- 전체 훈련 세트에 대한 비용 함수는?

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)})$$

- 비용함수는 손실함수들의 평균을 최소화

## 퀴즈

### # 10

```
import numpy as np

a = np.array([[3,0,1],[2,1,2]])
b = np.zeros([2,3])
c = np.ones([1,3])
d = a + b + c
print(d[1,1:3])
```

a = np.array([[3, 0, 1],[2,1,2]])

- 2x3 크기의 배열 a 선언
- a = [[3, 0, 1],[2,1,2]]

b = np.zeros([2,3])

- 2x3 크기의 배열 b 선언, 모든 원소 0으로 초기화
- b = [[0, 0, 0],[0, 0, 0]]

c = np.ones([1,3])

- 1x3 크기의 배열 c 선언, 모든 원소 1로 초기화

- `c = [[1, 1, 1]]`

`d = a+b+c`

- `c`를 브로드캐스팅하여 더하기
- `d = [[4, 1, 2], [3, 2, 3]]`

`print(d[1,1:3])`

- `d`의 1행, 1-2열 부분 배열 출력
- `[2, 3]`

### # 3

1. `np.random.randint(100)`
  - a. 0, 99 사이 랜덤 정수
2. `np.random.rand(100)`
  - a. 0, 1 사이 랜덤 수 100개로 이루어진 배열 생성
3. `np.random.randn(100)`
  - a. 평균 0, 표준편차 1인 정규분포에서 랜덤한 값 생성
4. `np.random.rand()`
  - a. 0에서 1 사이 랜덤값 생성