

## <신경망이란?>

뉴런(마치 레고 블록)들로 구성.

신경망 은닉 유닛이 입력을 받고 (노드), input layer이 입력과 출력을 연결.

주택의 가격에 영향을 미치는 것을 예시로 하면 가족의 수를 결정하기 위해서는 우편번호, 침실의 수 등이 영향을 미침

뉴런이나 예측기를 쌓으면서 신경망의 크기를 키움. 훈련세트에서  $u$  출력  $y$

## <지도학습> - 머신러닝의 한 기법

$x$ 와  $y$ 에 매핑되는 함수를 학습. (입력은 주택관련 특성, 출력은 주택의 가격)

(딥러닝 응용분야)

- 온라인 광고광고를 클릭할 것인지 아닌지 예측하는 것. 클릭할 만한 광고를 보여주는 것.
- 사진 태깅, 음성인식(음성파일을 넣으면 텍스트파일로 출력), machine translation 자율주행차들의 위치 정보 학습.

응용분야에 각각 적절한 다른 신경망들을 사용해야한다.

-부동산 어플리케이션: 표준 신경망 구조 사용

-온라인 광고: 표준신경망

-이미지분야: CNN 합성곱 신경망

-음성데이터(1차원 시계열 시퀀스 데이터): RNN

-언어 : 시퀀스데이터. RNN

-자율주행 : CNN, 하이브리드 신경망 구조

### <구조적/비구조적 데이터>

- 구조적: 데이터 베이스로 표현되는 데이터

(나이, 광고정보 침실의 개수.. 등등)

사용자 맞춤 . 정확한 예측.

- 비구조적: 음성파일, 이미지, 텍스트.

구조적 데이터보다 작업이 어려움. 딥러닝으로 비구조적 데이터 분석 수월해짐. 음성인식, 자연언어처리 같은 응용 분야 생김

### <왜 딥러닝이 뜨고 있을까?>

전통적인 학습 알고리즘(로지스틱 회귀분석, 서포트 벡터 머신) 은 데이터 양에 따라 performance 가 향상되지만 성능이 정체기에 이름.

#### 좋은 성능 발휘 조건

1. 많은 데이터를 이용하기 위한 큰 신경망 필요.
2. 많은 데이터 필요

많은 은닉 유닛. 많은 파라미터, 많은 데이터.

-데이터와 계산.

시그모이드 함수를 사용하면 경사가 0인 부분에서 문제가 발생한다. 활성화 함수를 relu로 바꾸면 양수에서 경사가 다 1로 같으므로 경사가 0으로 수렴할 가능성이 적음.

-빠른 계산

### <이진분류>- 신경프로그래밍의 기초

신경망을 학습하는 계산 과정: 정방향패스/ 역전파

- 로지스틱회귀 이용. : 이진분류를 위한 알고리즘

ex) 이미지 데이터가 주어졌을 때 rgb 3개의 픽셀 강도값을 나타내는 행렬을 한 열로 나타내기 위해 특성 벡터  $x$ 를 정의하고, 특성벡터  $x$ 로  $y$ 가 0인지 1인지 예측.

#### <변수 설명>

( $x, y$ )에서  $x$ 는  $n_x$ 차원 상의 특성벡터,  $y$ 는 0or1,  $m$ 개의 훈련샘플

$x$  행렬은  $x_1$ 을 한 칼럼으로,  $x_2$ 를 하나의 칼럼으로..  $x_m$ 까지.

$x$ 는  $n_x * m$  행렬 (python에서는  $X.shape$ 로 알 수 있음)

$y$  값도 칼럼으로.  $y_1, y_2, ..$  해서  $1 * m$  행렬

(이처럼 각각의 열로 놓는 것이 유용.)

#### <로지스틱 회귀분석>: 출력 레이블이 0or 1일 때 (이진분류)

- $\hat{y}$  을 알려주는 알고리즘.

(항상 0과 1 사이여야함, 그래서 선형회귀로 할 수 없음(전치행렬을 곱하면 1보다 큰 결과가 나오는 경우 많음(?)))

- 시그모이드 함수를 적용함. 0부터 1까지 매끈한 s자형의 모형.  $1/(1+e^{(-z)})$

$z$ 가 아주 크면 시그모이드는 1에 가깝고,  $z$ 가 아주 작거나 큰 음수면 시그모이드는 0에 수렴.

- $y$ 가 1일 확률을 잘 예측하게 하기 위해 파라미터  $w$ 와  $b$ 를 학습

( $b$ 는 인터셉트,  $b$ 와  $w$ 를 분리하는 것이 편함)

#### <비용함수와 손실함수>

• “ $\hat{y}$ 과  $y$ 의 제곱오차의 반” 공식은 최적화 함수가 블록하지 않아서 여러 개의 지역 최적값을 가지고 있어서 경사하강법이 전역최소값을 찾지 못할 수도 있기 때문에 로지스틱에서는 잘 사용하지 않음.

## 손실함수

★ 로지스틱 회귀에서는  $-(y \cdot \log(\hat{y}) + (1-y) \cdot \log(1-\hat{y}))$ 라는 손실함수 이용

1.  $y$  가 1일 때:  $-\log \hat{y} : \log(\hat{y})$ 이 커져야 loss가 작아지므로  $\hat{y}$ 이 1에 수렴하길 원함
2.  $y$ 가 0일 때 :  $(1-y)\log(1-\hat{y}) : \log(1-\hat{y})$ 이 커야 loss가 작아지므로  $\hat{y}$ 이 0에 수렴하길 원함

**비용함수:** 훈련세트 전체에 대해 얼마나 잘 추측되었는지 측정하는 함수

$J =$  손실함수를 각각의 훈련샘플에 적용한 값을 합들의 평균( $m$ )으로 나눈 값

손실함수가 하나의 훈련 샘플에 적용. 비용함수는 매개변수의 비용처럼 작용.

목적 : 손실함수를 최소화하는 매개변수  $w$ 와  $b$ 를 찾는 것

비용함수를 가장 작게 만드는  $w$ 와  $b$ 를 찾는 것

## <경사하강법>

볼록하지 않은 함수는 지역 최적값이 여러 개이기 때문에 볼록한 비용함수를 로지스틱 회귀에 사용한다.

가장 가파른 내리막 방향으로 한 단 계 내려간다. 이 과정을 반복하여 전역 최적값에 도달하게 된다.

계속해서  $w - \text{알파} \cdot (w)$ 의 미분계수(함수의 기울기)( $dw$ )를 곱한 값으로  $w$ 를 갱신한다.

알파: 학습률( 한 단계의 크기를 결정)

$w - \text{알파} \cdot dw$

$b - \text{알파} \cdot dw$

## <계산그래프>

특정한 출력값 변수를 최적화하고싶을 때 유용하다.

도함수 계산할 때는 반대로 (오른쪽에서 왼쪽으로) 계산한다.

### <계산그래프로 미분>

연쇄법칙

-역방향으로 도함수 계산.

-정방향 계산으로 비용함수 계산

### <로지스틱 회귀에서 미분>

$$da = -y/a + (1-y)/(1-a)$$

$$dz = dL/dz = a - y = dL/da * da/dz$$

w와 b 갱신

$$w_1 = w_1 - \alpha dw_1 \text{ 로 갱신}$$

m개의 훈련 샘플에 적용

w1에 대한 전체 비용함수의 도함수는 w1의 각 손실 항 도함수의평균

⇒ 전체적인 경사를 구할 수 있음

하지만 for 문 2개 만들어야함

n개의 특성을 반복하는 for 문 필요. 비효율적

⇒ 벡터화로 for 문 제거

Handwritten mathematical derivations for logistic regression gradients.

Left side (Forward and Backward Pass for a single sample  $i$ ):

- $J = 0; \underline{dw_1} = 0; \underline{dw_2} = 0; \underline{db} = 0$
- For  $i = 1$  to  $m$
- $z^{(i)} = w_1^{(i)} x_1^{(i)} + b$
- $a^{(i)} = \sigma(z^{(i)})$
- $J^{(i)} = -[y^{(i)} \log a^{(i)} + (1-y^{(i)}) \log (1-a^{(i)})]$
- $\underline{dz^{(i)}} = a^{(i)} - y^{(i)}$
- $\underline{dw_1} += x_1^{(i)} \underline{dz^{(i)}}$
- $\underline{dw_2} += x_2^{(i)} \underline{dz^{(i)}}$
- $\underline{db} += \underline{dz^{(i)}}$
- $n = 2$
- End of loop
- $\underline{dw_1} = m; \underline{dw_2} = m; \underline{db} = m.$

Right side (Vectorized Update Rules):

- $\underline{dw_1} = \frac{\partial J}{\partial w_1}$
- $w_1 := w_1 - \alpha \underline{dw_1}$
- $w_2 := w_2 - \alpha \underline{dw_2}$
- $b := b - \alpha \underline{db}$
- Vectorization

전