

[딥러닝 2단계] 7. 다중 클래스 분류


1. Softmax Regression

softmax regression

- 로지스틱 회귀를 일반화
- 여러 클래스 예측에 사용

Recognizing cats, dogs, and baby chicks

- $C = \text{class의 개수} = 4$
 - 고양이: 클래스 1, 개: 클래스 2, 병아리: 클래스 3, 해당 x: 클래스 0



- $n^L = 4 = C$
 - 첫번째 단위 = $P(\text{other}|x)$ = 입력값 x 가 주어졌을 때 기타 클래스가 나올 확률
 - 두번째 = $P(\text{cat}|x)$
 - 두번째 = $P(\text{dog}|x)$
 - 네번째 = $P(\text{병아리}|x)$
- 출력값 $\hat{y} = (4, 1)$ 차원 벡터
- \hat{y} 각 값들의 합 = 1

Softmax layer

Activation function

- 입력값과 출력값이 모두 벡터


$$t = e^{z^{[L]}}$$

$$a^{[L]} = e^{z^{[L]}} / \sum_{j=1}^4 t_j$$

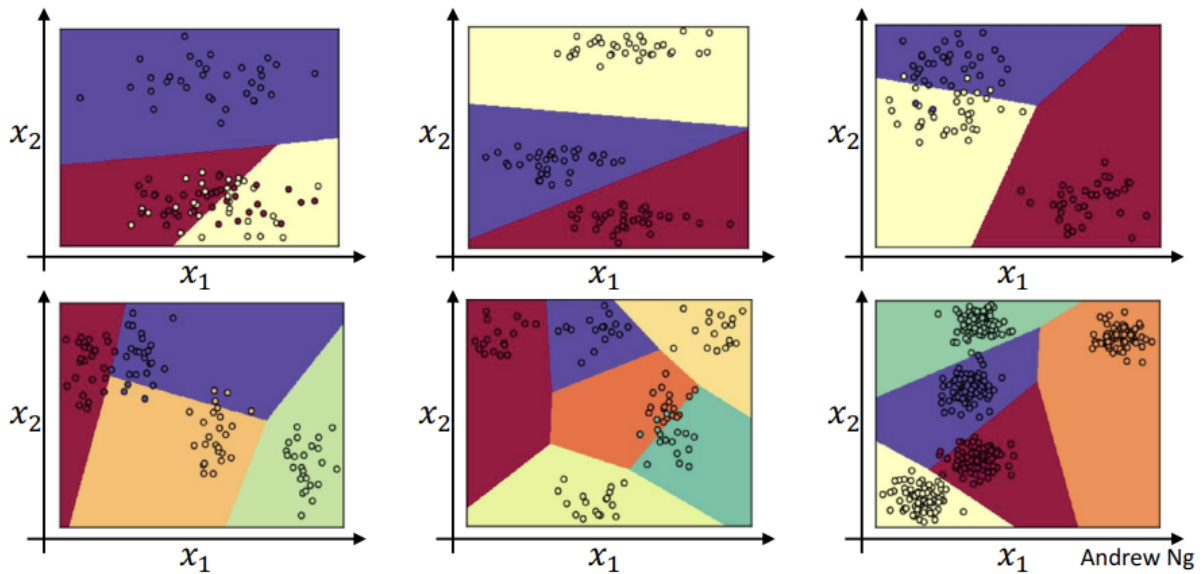
$$a_i^{[L]} = t_i / \sum_{j=1}^4 t_j$$

예시

클래스 0,1,2,3이 될 확률 구하기



Softmax examples



- 두 클래스 사이의 경계가 선형
- 만약 은닉 유닛이 여러 개인, 더 깊은 신경망을 다룬다면 여러 클래스를 분류하기 위해 더 복잡하고 비선형의 경계도 볼 수 있을 것

2. Softmax 분류기 훈련시키기

Understanding softmax

$(4,1)$
 $z^{[L]} = \begin{bmatrix} 5 \\ 2 \\ -1 \\ 3 \end{bmatrix} \quad t = \begin{bmatrix} e^5 \\ e^2 \\ e^{-1} \\ e^3 \end{bmatrix}$

$C=4 \quad g^{[L]}(\cdot)$

"soft max"
 $a^{[L]} = g^{[L]}(z^{[L]}) = \begin{bmatrix} e^5 / (e^5 + e^2 + e^{-1} + e^3) \\ e^2 / (e^5 + e^2 + e^{-1} + e^3) \\ e^{-1} / (e^5 + e^2 + e^{-1} + e^3) \\ e^3 / (e^5 + e^2 + e^{-1} + e^3) \end{bmatrix} = \begin{bmatrix} 0.842 \\ 0.042 \\ 0.002 \\ 0.114 \end{bmatrix}$

"hard max"
 $\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$

Softmax regression generalizes logistic regression to C classes.

If $C=2$, softmax reduces to logistic regression. $a^{[L]} = \begin{bmatrix} 0.842 \\ -0.158 \end{bmatrix}$

- hardmax: z 의 원소를 살펴보고 가장 큰 값이 있는 곳에 1을 나머지에 0을 갖는 벡터로 대응시키는 것
- softmax: z 를 확률들로 대응시키는 것



소프트맥스 회귀나 활성화 함수는 두 클래스만 다루는 로지스틱 회귀를 일반화한 것이다.

- $C=2 \rightarrow$ 로지스틱 회귀와 동일

Loss function

하나의 훈련 샘플

- $y=[0 \ 1 \ 0 \ 0], \hat{y}=[0.3 \ 0.2 \ 0.1 \ 0.4]$

$$L(\hat{y}, y) = - \sum_{j=1}^4 y_j \log \hat{y}_j$$


- $> -y_2 \log \hat{y}_2 = -\log \hat{y}_2$
- L 을 작게 만들기 위해선 \hat{y}_2 을 크게 만들어야함
- 입력값 x 에 대응하는 출력값의 확률을 키워주는 것

전체 훈련 세트

$$J(w^{[1]}, b^{[1]}, \dots) = 1/m \sum_{i=1}^m L(\hat{y}^{(i)}, y^{(i)})$$

$$Y = [y^{(1)} \ y^{(2)} \dots \ y^{(m)}]$$

Gradient descent with softmax



- Softmax 와 손실함수를 결합한 역전파의 값 $dz^{[L]}$ 은 $z^{[L]}$ 에 대해 편미분한 것

해당글은 부스트코스의 [\[딥러닝 2단계\] 7. 다중 클래스 분류](#) 강의를 듣고 작성한 글입니다.

[velog 링크](#)

