



15주차_다중 클래스 분류 및 프로그래밍 프레임워크 소개

≡ 링크

<https://velog.io/@pehye89/Euron-15주차-다중-클래스-분류-및-프로그래밍-프레임워크-소개>

▽ 1 more property

7. 다중 클래스 분류

Softmax

- 로지스틱 회귀를 일반화한 소프트맥스 함수
- 두 개의 클래스가 아닌 여러 클래스나 C 중 하나를 인식할 때 예측에서 사용할 수 있다


고양이, 개, 병아리 분류




3 1 2 0 3 2 0 1

- 여기서 C 를 클래스의 갯수라고 하자
- 그렇다면 출력층이 총 4개이며, 각 클래스가 될 확률을 알려주는 신경망을 만들 수 있다.
- 모든 출력층들의 결과, 즉 \hat{y} 의 합은 1이 되어야할 것이다.

Softmax Activation Function



- 마지막 층에서 z 를 계산한 후, activation function이 아닌 softmax function을 통과하게 될 것이다.
- $t = e^{z^{[L]}}$ where its shape is $(4, 1)$
- $a^{[L]} = \frac{e^{z^{[L]}}}{\sum_{j=1}^4 t_j}$, where its shape is $(4, 1)$
 - $a_i^{[L]} = \frac{t_i}{\sum_{j=1}^4 t_j}$
- 즉, z 값에 e 를 취해서 임시변수 t 값을 계산하여 정규화한 a 를 계산하는 과정을 **softmax activation function**으로 요약할 수 있다.
- 이전 활성화 함수는 실수를 입력받아 실수를 결과로 출력했지만, 이 소프트맥스 활성화 함수에 특이한 점은 $(4,1)$ 벡터를 받아 $(4,1)$ 벡터를 출력함에 있다.



만약 은닉층이 없고 x 를 바로 소프트맥스 함수에 적용시킨다고 하면, (클래스가 2개 이상인) 선형 기준을 갖고 있는 로지스틱 회귀의 일반적인 형태로 학습한다.

💡 만약 훨씬 복잡해진다면 비선형 형태가 될 수는 있지만, 대부분의 모델에서 중요한 것은 클래스들 사이의 경계가 선형이라는 것

Softmax Classifier 훈련

$$z^{[L]} = \begin{bmatrix} 5 \\ 2 \\ -1 \\ 3 \end{bmatrix} \quad t = \begin{bmatrix} e^5 \\ e^2 \\ e^{-1} \\ e^3 \end{bmatrix}$$

$$g^{[L]}(z^{[L]}) = \begin{bmatrix} e^5 / (e^5 + e^2 + e^{-1} + e^3) \\ e^2 / (e^5 + e^2 + e^{-1} + e^3) \\ e^{-1} / (e^5 + e^2 + e^{-1} + e^3) \\ e^3 / (e^5 + e^2 + e^{-1} + e^3) \end{bmatrix} = \begin{bmatrix} 0.842 \\ 0.042 \\ 0.002 \\ 0.114 \end{bmatrix}$$

💡 Softmax regression generalizes logistic regression to C classes.
If $C = 2$, when we apply softmax, the result is reduced to logistic regression.

손실함수 Loss Function

$$y = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad \begin{array}{l} \text{cat} \\ y_2 = 1 \\ y_1 = y_3 = y_4 = 0 \end{array}$$

$$\mathcal{L}(\hat{y}, y) = - \sum_{j=1}^J y_j \log \hat{y}_j$$

$$- y_2 \log \hat{y}_2 = - \log \hat{y}_2$$

- 여기서 y 값에서 "정답"이 1이면, 나머지 값들이 0일 것이다.
- 그렇다면 이 값을 통해 loss값을 계산할 때 y_i 의 합을 구할 때, 특정 y_i (이 예시는 y_2)를 제외하면 다 0이기 때문에 결국 y_2 를 사용하는 것과 같을 것이다.

- 그렇기에 훈련세트에 대응하는 출력값의 확률을 가장 키우는 것이 목표이다.
- 이 논리는 통계학의 최대우도추정과 유사하다 (Maximum Likelihood)

경사하강법 Back Propagation


- 정방향 전파에서는 z 값을 계산하여 (shape은 $(4, 1)$) a 를 계산하고, 이 $a = \hat{y} \rightarrow L(\hat{y}, y)$ 로 손실함수를 계산했다.
- 역방향 전파에서 중요한 것은 dz 를 계산할 때, 이 미분값이 $(C, 1)$ 벡터들의 차이이기 때문에 결과도 $(C, 1)$ 가 될 것을 기억하는 것이다.

$$dz^{[L]} = \hat{y} - y$$


- 만약 `tensorflow`를 사용하게 된다면, 정방향 전파에 집중해도 알아서 미분 계산을 해줄 것이다.

8. 프로그래밍 프레임워크 소개

지역 최적값에 대한 문제




- 그동안 지역 최소값에 대한 문제는 왼쪽의 그림처럼 묘사되었다.
- 하지만 더 깊고 복잡한 고차원의 신경망이 다뤄지면서, 실제로는 오른쪽과 같은 형태가 더 자주 나타난다는 것을 알게되었다.



Calctworkshop.com

[source](#)

- 여기서 나오는 것은 지역 최소값이 아닌 안장점(saddle point)이며, 이 안장점은 convex와 concave 형태로 이뤄져있다.
- 안정지대(plateaus), 즉 미분값이 0에 가까운 값들이 많은 부분은 학습을 느리게 하기 때문에 문제가 된다.
- 이 문제는 단순히 0에 가까운 값으로 움직이는 것이 아닌, 모멘텀이나 RMSProp, Adam 등에 알고리즘을 통해 왼쪽이나 오른쪽에 무작위로 가게 된다면 더 빠르게 이 안정지대를 벗어날 수 있을 것이다.



- 💡 만약 충분히 큰 고차 신경망을 학습할 때는 지역 최소값이 아닌 안정지대를 벗어날 수 있는
나가 더 많이 문제가 된다.

Tensorflow

$$J(w) = w^2 - 10w + 25 = (w - 5)^2$$

위 공식을 최소화하는 w 의 값은 5일 것이다. 이것을 모른다는 가정을 하고 텐서플로우가 어떻게 이
식을 최소화하는지 알아보자.

- 텐서플로우는 장점 손실함수만 정의해봐도 경사하강법과 optimizer를 자동으로 해준다는 것이
다.
- 텐서플로우에서 손실함수를 정의한다는 것은, 텐서플로우가 계산 그래프를 그리도록 하는 것이
다.

```
import numpy as np import tensorflow as tf # w를 0으로 초기화 시켜주는 것 # 우리가 최적화하  
고 싶은 변수 w = tf.Variable(0, dtype=tf.float32) # 비용함수를 정의 cost = tf.add(w**2,  
tf.multiply(-10,w), 25) # cost = w**2 - 10*w + 25 로도 가능하다 # 경사하강법을 사용하여 비  
용함수를 최소화하는 학습 알고리즘 train =  
tf.train.GradientDescentOptimizer(0.01).minimize(cost)
```

```
init = tf.global_variables_initializer() session = tf.Session() session.run(init) # 아직  
아무것도 학습시키지 않았기 때문에 결과는 여전히 0일 것이다. print(session.run(w)) # 0.0 # 이  
위의 코드는 관용적으로 쓰인다. # 위 코드가 아닌 아래와 같은 코드를 사용하는 프로그래머들도 있다  
# 같은 결과를 의미하지만, with를 사용하는 것이 파이썬을 사용할 때 오류나 예외의 경우 더 깔끔하  
다. with tf.Session() as session: session.run(init) print(session.run(w))
```

```
# 1번의 경사하강법 후의 w의 값을 계산 session.run(train) print(session.run(w)) #0.1
```

```
# 1+1000번의 경사하강법 후의 w의 값을 계산 for i in range(1000): session.run(train) # 정답  
인 5에 매우 가까워졌다는 것을 알 수 있다 print(session.run(w)) # 4.9999
```

- 이 예시에서는 w 에 관해 고정된 함수를 최소화한다.
- 이제 학습 데이터의 역할을 하는 x 를 정의해준다.

```
coefficient = np.array([[1.], [-10], [25.]]) w = tf.Variable(0, dtype=tf.float32) #  
placeholder는 나중에 값을 정의해줄거라고 미리 말해주는 것과 같다 x =  
tf.placeholder(tf.float32, [3,1]) cost = x[0][0]*w**2 + x[1][0]*w + x[2][0] train =  
tf.train.GradientDescentOptimizer(0.01).minimize(cost) init =  
tf.global_variables_initializer() session = tf.Session() session.run(init)
```

```
# 이렇게 한다면 coefficient를 쉽게 바꿀 수 있게 한다 session.run(train, feed_dict=  
{x:coefficient}) print(session.run(w)) for i in range(1000): session.run(train,  
feed_dict={x:coefficient}) print(session.run(w))
```

