


이진 분류



$$(x, y), x \in \mathbb{R}^n, y \in \{0, 1\}$$

m개의 training sample : $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(n)}, y^{(n)})\}$

$$X = \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ x^{(1)} & x^{(2)} & \dots & x^{(n)} \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix} \begin{matrix} n \\ m \end{matrix} \Rightarrow X \in \mathbb{R}^{n \times m}$$

$x.shape = (n \times m)$

$$Y = [y^{(1)}, y^{(2)}, \dots, y^{(n)}] \Rightarrow Y \in \mathbb{R}^{1 \times m}$$

$y.shape = (1 \times m)$

32비트 float \leftarrow use in Logistic Regression

Given x , we want $\hat{y} = p(1|x)$. 아닐때 1일 확률

$$0 \leq \hat{y} \leq 1$$

i) $x \in \mathbb{R}^n$

정답 \hat{y}

ii) parameters: $w \in \mathbb{R}^n$, $b \in \mathbb{R}$

output: $\hat{y} = w^T x + b \Rightarrow$ 연속값도 있고, 1보다 큰 수도 있음

① $\hat{y} = \underbrace{\sigma(w^T x + b)}_z$
시그모이드 함수

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

② $z \rightarrow \infty, \sigma(z) \approx 1$
 $z \rightarrow -\infty, \sigma(z) \approx 0$



* 신경회기*

$$\hat{y} = w^T x + b$$

* 로지스틱 회귀 *


$$\hat{y} = \sigma(w^T x + b)$$

σ 값이
0~1 범위를
범위값 속 있음

로지스틱 회귀의 비용함수

• Logistic Regression

$$\hat{y}^{(i)} = \sigma(w^T x^{(i)} + b^{(i)}), \quad \sigma(z) = \frac{1}{1 + e^{-z}} : \hat{y} \text{ 값이 } 0 \sim 1 \text{ 사이의 값이 되도록 "시그모이드" 함수 적용.}$$



• Loss function ($\mathcal{L}(\hat{y}, y)$)

: \hat{y} (예측값) 과 y (실제값) 의 오차의 크기를 나타내는 함수

* 로지스틱의 오차함수 *

$$\mathcal{L}(\hat{y}, y) = -(y \log \hat{y} + (1-y) \log (1-\hat{y}))$$

if $y = 1$, $\mathcal{L}(\hat{y}, y) = -\log \hat{y} \leftarrow$ we want $\log \hat{y} \uparrow$, $\odot \hat{y}$ to be large \leftarrow 가장 큰 값은 1 $\Rightarrow y \approx \hat{y}$

if $y = 0$, $\mathcal{L}(\hat{y}, y) = -\log (1-\hat{y}) \leftarrow$ " $\log (1-\hat{y}) \uparrow$, $\odot \hat{y}$ to be small

시그모이드 함수에서
가장 큰 값은 1
 $\Rightarrow y \approx \hat{y}$
가장 작은 값은 0
 $\Rightarrow y \approx \hat{y}$

• Cost function


vs Loss function \Rightarrow 손실함수는 Training set 1개의 데이터 적용

But, cost function: $J(w, b) = \frac{1}{m} \sum \mathcal{L}(\hat{y}, y) = -\frac{1}{m} \sum [y(\log \hat{y} + (1-y) \log (1-\hat{y}))]$


\Rightarrow Training set 모두가 데이터 각각 적용한 값들의 평균

☺ $J(w, b)$ 를 minimize 하는 w, b 를 찾아야 함

경사하강법



(1) with respect to "w"



Repeat

update $w = w - \alpha \frac{dJ}{dw}$

learning rate

$\frac{dJ}{dw} > 0$

부호가 \ominus 가 된다

☺ 음의 방향 (왼쪽)으로
w가 update

$\frac{dJ}{dw} < 0$

부호가 \oplus 가 된다

☺ 양의 방향 (오른쪽)으로
w가 update.

☺ To minimize $J(w, b)$,

we update w, b using Gradient Descent

$$\begin{cases} w = w - \alpha \frac{dJ}{dw} \\ b = b - \alpha \frac{dJ}{db} \end{cases}$$

계산 그래프

compute $J(a, b, c) = 3(a + bc) = 3(5 + 3 \cdot 2) = 33$

(i) First, compute bc

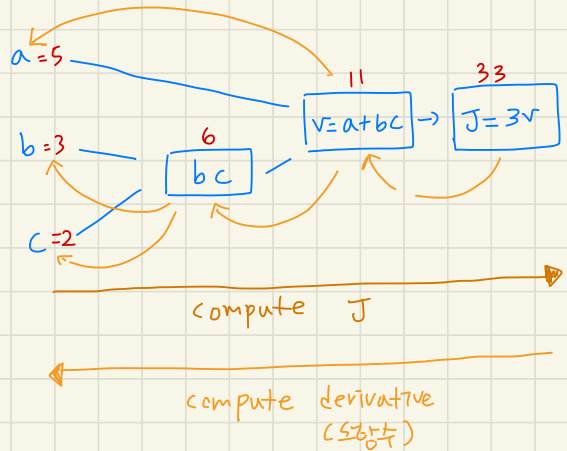
$u = bc$

(ii) second, compute $a + bc$

$v = a + u$

(iii) Finally, compute J .

$J = 3v$



*compute Derivative

$\frac{dJ}{dv}$ 가 $\frac{dJ}{da}$ 의 영향을 줌


$$\frac{dJ}{dv} = \frac{d(3v)}{dv} = 3$$

$$\frac{dJ}{da} = \frac{d(3v)}{da} = \frac{d(3a + 3u)}{da} = 3 = \frac{dJ}{dv} \cdot \frac{dv}{da}$$

$$\therefore \frac{dv}{da} = 1$$

$$\frac{dJ}{dv} \cdot \frac{dv}{da} = 3$$

3 1



도함수 구하는 방향

i.e. $\frac{dJ}{dc}$ 를 계산하기 위해서는 우선 $\frac{dJ}{du}$ 를 먼저 계산함.

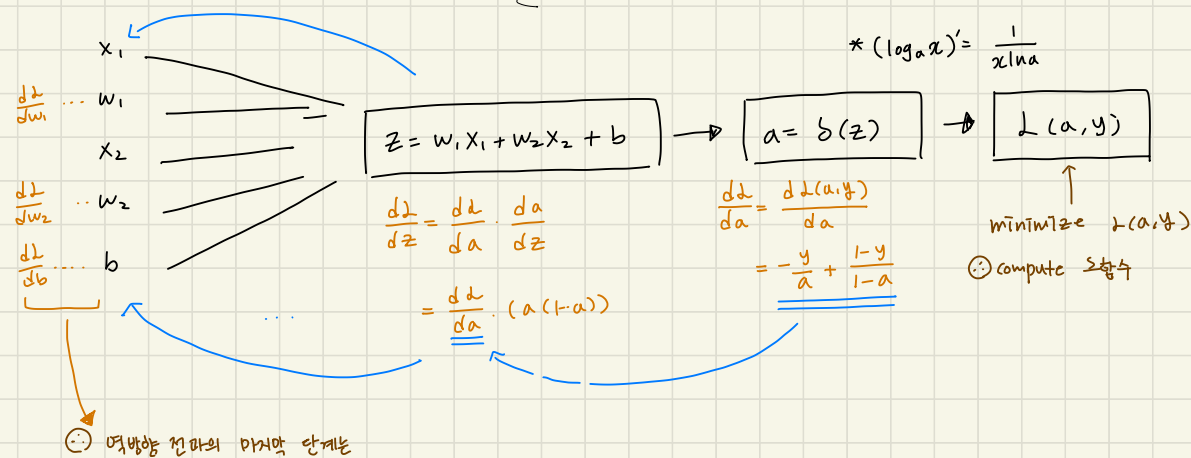
로지스틱 회귀의 평가방법

$$z = w^T x + b$$

$$\hat{y} = u = \delta(z)$$

$$L(a, y) = -(y \log(a) + (1-y) \log(1-a))$$

$$[w_1 \ w_2] \begin{bmatrix} x_{11}^{(1)} & x_{12}^{(2)} \\ x_{21}^{(1)} & x_{22}^{(2)} \end{bmatrix} + b$$



☹️ 여섯방앗간 집사의 마지막 단계는

$J(a, b)$ 를 minimize 하기 위해 w, b 를 얼마나 바꿔야 하는지 계산하는 것

$$\Rightarrow \frac{d^2}{dw} \quad \& \quad \frac{d^2}{db}$$

G.D on n Samples

$$J=0, dw_1=0, dw_2=0, db=0$$

For $j=1$ to m :

$$z^{(T)} = w^T x^{(T)} + b$$

$$a^{(i)} = \phi(z^{(i)})$$

$$J = - [y^{(i)} \log(a^{(i)}) + (1 - y^{(i)}) (\log(1 - a^{(i)}))] \quad \text{--- (1)}$$

$$dz^{(1)} = a^{(1)} - y^{(1)}$$

$$dw_1 + = x_1^{(1)} + dz^{(1)}$$

$$dw_2 = x_2^{(i)} + dz^{(i)}$$

$$db = dz^{(i)}$$

$$[u \quad v_z] \begin{bmatrix} X_{11}^{(1)} & X_{12}^{(2)} & \dots & X_{1n}^{(m)} \\ X_{21}^{(1)} & X_{22}^{(2)} & \dots & X_{2n}^{(m)} \end{bmatrix} + b$$

$$w_1 = w_1 - \alpha \frac{dJ}{dw_1}$$

$$w_2 := w_2 - \alpha \frac{dJ}{dw_2} = dw_2$$

$$b := b - \alpha \frac{dJ}{db} = db$$

중간 가치 정리