

## 2. 신경망과 로지스틱 회귀

이진분류

로지스틱 회귀

Cost function

Gradient Descent

Derivatives with Computation Graph

Logistic Regression Gradient Descent

### 이진분류

#### 1. 개념

- input  $x$ 를 1 또는 0으로 분류
- logistic regression란 이진 분류를 하기 위해 사용되는 알고리즘임

### 로지스틱 회귀

Logistic Regression:

이진 분류 문제에 사용되는 알고리즘

$x$ : input	$y$ : 실제 값	$\hat{y}$ : 예측값	$(0 \leq \hat{y} \leq 1)$
$\hat{y} = \sigma(w^T x + b)$	where	$\sigma(z) = \frac{1}{1 + e^{-z}}$	$\sigma(z)$ 함수를 통해 $\hat{y}$ 이 0과 1 사이의 값을 갖게 함.
$\Rightarrow \hat{y}$ 를 더 잘 예측하듯 $w, b$ 학습.			

### Cost function

Loss function

- input  $x$ 에 대한 실제값과 예측값의 오차를 계산
- mean squared error는 local optimal에 빠질 수 있으므로 사용하지 않음

$$L(\hat{y}, y) = -(y \log \hat{y} + (1-y) \log (1-\hat{y}))$$

$$\text{if } y=1: L(\hat{y}, y) = -\log \hat{y} \rightarrow \hat{y} \approx 1$$


$$y=0: L(\hat{y}, y) = -\log (1-\hat{y}) \rightarrow \hat{y} \approx 0$$

Cost function

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m L(\hat{y}^{(i)}, y^{(i)})$$

## Gradient Descent


- logistic regression에서 cost function  $J(w, b)$ 를 최소화하기 위해 gradient descent 방법을 쓴다
- steps
  - 1) initialize  $w, b$ : 주로 0으로 초기화 함
  - 2) 가장 가파른 방향으로  $w, b$ 를 update



## Derivatives with Computation Graph

- computation graph에서 back propagation을 통해 derivatives를 구할 수 있음

## Derivatives with computation graph



$$dv : \frac{dJ}{dv} = 3$$

$$db : \frac{dJ}{db} = \frac{du}{db} \frac{dJ}{du} = 3 \cdot 2 = 6$$

$$da : \frac{dJ}{da} = \frac{dJ}{dv} \frac{dv}{da} = 3$$

$$dc : \frac{dJ}{dc} = \frac{du}{dc} \frac{dJ}{du} = 3 \cdot 3 = 9$$

$$du : \frac{dJ}{du} = \frac{dv}{du} \frac{dJ}{dv} = 3$$


## Logistic Regression Gradient Descent

- gradient descent으로 loss function  $L(a, y)$ 를 최소화하는 파라미터  $w, b$ 를 찾음
- 하나의  $x$ 에 대한 경사하강법

$$z = w^T x + b$$

$$\hat{y} = a = \sigma(z)$$

$$L(a, y) = -(y \log(a) + (1-y) \log(1-a))$$



$$\begin{aligned} dw_1 &= x_1 dz \\ dw_2 &= x_2 dz \\ db &= dz \end{aligned} \Rightarrow \begin{cases} w_1 := w_1 - \alpha dw_1 \\ w_2 := w_2 - \alpha dw_2 \\ b := b - \alpha db \end{cases} \text{update params.}$$

- m개 샘플의 경사하강법 알고리즘

## Gradient descent on m training examples

$$J = 0 ; dw_1 = 0 ; dw_2 = 0, db = 0$$

For  $i=1$  to  $m$  :

$$z^{(i)} = w^T x^{(i)} + b$$

$$a^{(i)} = \sigma(z^{(i)})$$

$$J += - [y^{(i)} \log a^{(i)} + (1 - y^{(i)}) \log (1 - a^{(i)})]$$

$$dz^{(i)} = a^{(i)} - y^{(i)}$$

$$dw_1 += w_1^{(i)} + dz^{(i)}$$

$$dw_2 += w_2^{(i)} + dz^{(i)}$$

$$db += dz^{(i)}$$

$$J /= m$$

$$dw_1 /= m ; dw_2 /= m ; db /= m$$

$$w_1 := w_1 - \alpha dw_1$$

$$w_2 := w_2 - \alpha dw_2$$

$$b := b - \alpha db$$

For문 비효율적  $\rightarrow$  벡터화

- 두 개의 for 문
  - m개의 샘플에 대한 반복문
  - 파라미터  $w_1, w_2, \dots, w_n$ 에 대한 반복문
- for문은 비효율적이라 벡터화를 사용함